Роль AI-інженера та анатомія AI-продукту

Заняття 1

AI Engineering

Білоус Андрій

r_d

ПЛАН ЗАНЯТТЯ

00–10	Знайомство, формат курсу, як працюємо з ДЗ
10–25	Хто такий AI-інженер у 2026 році
25–35	Ринок: попит і зарплати (світ та Україна)
35–60	Анатомія AI-продукту: шари та шлях запиту
60–75	Від демо до продакшну + тренди осені 2026
75–90	Карта курсу, наскрізний проєкт, Q&A



ХТО ТАКИЙ AI-ІНЖЕНЕР

AI-інженер — software engineer, який будує продукти поверх foundation-моделей (API або open weights). Відповідає за контекст, інструменти, оркестрацію, evals і поведінку системи в продакшн. Зазвичай не тренує моделі.

Software Engineer

Детерміновані системи

- Бекенд, фронтенд, інфраструктура
- Тести: правильно / неправильно
- Дедалі більше пише код разом із coding-агентами

AI Engineer

Продукт поверх LLM

- Context, RAG, tools / MCP, агенти
- Evals і error analysis замість unit-тестів
- Guardrails, observability, cost / latency

ML Engineer

Моделі та дані

- Тренування, fine-tuning, serving
- Data pipelines, feature stores
- MLOps, GPU, метрики моделі

Джерела: Hamel Husain, «AI Product Engineering Notes» (12.08.2026); ODSC, «12 Most In-Demand AI Job Roles in 2026» (09.09.2026)

РИНОК 2026: ПОПИТ І ЗАРПЛАТИ

+143%

ріст вакансій AI Engineer у США за рік — найшвидше зростаюча професія за LinkedIn

LinkedIn Jobs on the Rise 2026 via ODSC

$3 100

медіана AI Engineer в Україні (ML Engineer — $3 500, Head of AI/DS — $6 400)

DOU, зарплати літо 2026

+73%

ріст вакансій з вимогою AI-навичок в Україні за рік — при падінні всіх dev-вакансій на 6%

Djinni, травень 2026

57%

команд уже мають агентів у продакшні, але лише 52% запускають offline evals

LangChain, State of Agent Engineering

ЩО РЕАЛЬНО РОБИТЬ AI-ІНЖЕНЕР

01

Evals та error analysis

Дивиться на дані, будує golden set, міряє якість до і після змін

02

Context та RAG

Що саме потрапляє в контекст моделі: документи, пам'ять, стан

03

Tools та MCP

Підключає API, бази, сервіси компанії як інструменти для моделі

04

Оркестрація агентів

Workflow чи агент, цикли, сабагенти, human-in-the-loop

05

Guardrails та безпека

Валідація схем, права доступу, захист від prompt injection

06

Observability та вартість

Трейси, latency, cost per task, роутинг між моделями

АНАТОМІЯ AI-ПРОДУКТУ

UX / продукт · чат, копілот, фонова автоматизація	зан. 1, 18
Оркестрація · agent loop, workflow, сабагенти	зан. 11, 13
Контекст · промпти, RAG, пам'ять, стан	зан. 4, 6–8,13
Інструменти / MCP · API, БД, пісочниці для коду	зан. 12
Доступ до моделей · gateway, роутинг, кеш	зан. 2–3, 16
API-шар та інфраструктура · сервіс, черги, деплой	зан. 15

HARNESS · OPS

Наскрізно через усі шари:

- Evals — зан. 9
- Guardrails і безпека — зан. 0, 17
- Observability — зан. 17
- Вартість і latency — зан. 16

«Різниця між демо та продакшн-агентом — це harness»

Модель шарів за InfoQ, «The Agent Harness: What it is and Two Ways to Build One» (25.09.2026)

ШЛЯХ ОДНОГО ЗАПИТУ КРІЗЬ СИСТЕМУ

Приклад: «Де моє замовлення #4812 і чи можна змінити адресу доставки?» — бот підтримки магазину

1 → **Вхідні guardrails**
PII, prompt injection, доступи

2 → **Контекст**
історія діалогу, RAG по політиках доставки

3 → **Модель**
через gateway: роутинг, кеш

4 → **Tool calls**
get_order(), update_address()

5 → **Вихідна валідація**
схема, політики, впевненість

6 → **Відповідь**
стрімінг користувачу

Під кожним кроком — трейс

Кожен крок пише span: що потрапило в контекст, які tools викликались, скільки токенів і мілісекунд коштував крок. Без цього неможливо ні дебажити, ні будувати evals, ні рахувати cost per task.

ВІД ДЕМО ДО ПРОДАКШНУ

ДЕМО

- Один промпт і одна модель
- «Перевірили на 5 прикладах — працює»
- Немає обмежень на кроки та бюджет
- Помилки видно лише зі скарг

ПРОДАКШН

- Gateway, версіонування промптів, кілька моделей
- Golden set + online evals, regression перед релізом
- Pydantic-схеми на виході, права на кожен tool
- Трейси, cost attribution по командах і фічах

15% → 1.5% рівень галюцинацій у рітейл-компанії після впровадження платформних контролів: gateway, schema enforcement, golden-set evals, авторизація MCP



InfoQ, «The Platform Engineering Playbook for Production LLMs» (05.10.2026)

ТРЕНДИ ОСЕНІ 2026

Harness як одиниця інженерії

Agents API на OpenAI DevDay, нова ера Claude Code: конкурують уже не моделі, а обв'язка навколо них.

Context engineering

97% вважають context engineering важливим, але лише 4% мають продакшн-рівень. 73%: агенти ламаються через контекст, а не модель.

Eval-driven development

Інструменти авто-evals уже з'явились, але практики наголошують: спочатку дивись на дані, потім будуй evals.

Coding-агенти змінюють роль

Інженери Anthropic використовують AI у 59% роботи, але повністю делегують лише 20%. Цінність — у специфікаціях і перевірці.

Latent Space (29–30.09.2026); Redis «State of Context Engineering 2026»; Hamel Husain (30.09.2026); InfoQ (13.08.2026)

Ще один сигнал: токенів, згенерованих агентами, вже більше, ніж людських (a16z State of Markets 2026), тож вартість і latency стають ключовою інженерною задачею.

КАРТА КУРСУ ТА НАСКРІЗНИЙ ПРОЕКТ

Блок 1
Основи LLM
зан. 1–5
ДЗ до 27.10

Блок 2
Дані та RAG
зан. 6–10
ДЗ до 13.11

Блок 3
Агенти та MCP
зан. 11–14
ДЗ до 02.12

Блок 4
Продакшн
зан. 15–18
Demo Day 10.12

ЗАВДАННЯ ДО ЗАНЯТТЯ 2

- Оберіть задачу для наскрізного проєкту: свою робочу або дефолтну (бот підтримки з прикладу).
- Розкладіть її за підзадачі: які шари потрібні, де дані, які tools, що може піти не так.
- Запишіть критерій успіху та 10 реальних прикладів запитів з очікуваною відповіддю — це ваш перший eval-набір.

Q&A

???

r_d

ЗАВЖДИ Є КУДИ ЗРОСТАТИ