Інтеграція LLM: API та self-hosted

Заняття 3

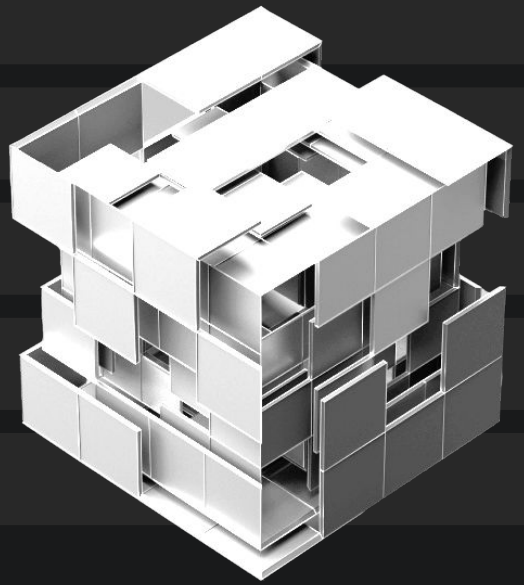
AI Engineering

Білоус Андрій

r_d

ПЛАН ЗАНЯТТЯ · 90 ХВИЛИН

00–05	Роадмап: де ми в курсі, результати, правила питань
05–15	Способи підключення, патерни, що ламається в продакшні
15–25	Tokenomics і latency: рахуємо до рахунку
25–30	Self-hosted, вибір моделі · пауза на 1–2 питання
30–65	Практика: одна задача — три реалізації
65–75	Зв’язок з кейсом 1: крок 2
75–90	Q&A з чату заняття



ТРИ СПОСОБИ ПІДКЛЮЧИТИ МОДЕЛЬ

Провайдер
OpenAI, Anthropic, Google

Агрегатор
OpenRouter: сотні моделей, один ключ

Self-hosted
Ollama, vLLM: модель на вашому залізі

OpenAI-сумісний API
Майже той самий код для всіх трьох. Відрізняються structured output, tool calling, кешування, поля usage.

Залежність від провайдера
Ліміти, ціни й доступність ви не контролюєте. Тому код має переживати збої: timeout, retry, fallback.

Що змінюється між трьома

`base_url` адреса сервера

`model` назва моделі

Плюс ключ. Решта коду однакова — це і є сьогоднішня практика.

ПАТЕРНИ ІНТЕГРАЦІЇ

Патерн	Проблема	Як у коді	Коли
Timeout	Запит «висить»	OpenAI(timeout=30)	Завжди
Retry з backoff	429, 5xx, обрив	max_retries=2 · 1 → 2 → 4 с + jitter	Завжди
Structured output + валідація	Зламаний JSON	JSON Schema + Pydantic, повтор при помилці	Екстракція
Fallback	Провайдер недоступний	Друга модель або провайдер	Продакшн

ЩО ЛАМАЄТЬСЯ В ПРОДАКШНІ

Обрізана відповідь

finish_reason = "length": помилки API немає, а JSON зламаний. Перевіряйте завжди.

Не влазить контекст

400 через довжину не лікується повтором. Обрізайте історію або ділить документ.

Repair loop

Невалідний JSON → повтор з текстом помилки для моделі. Кожна спроба коштує, тому ліміт спроб.

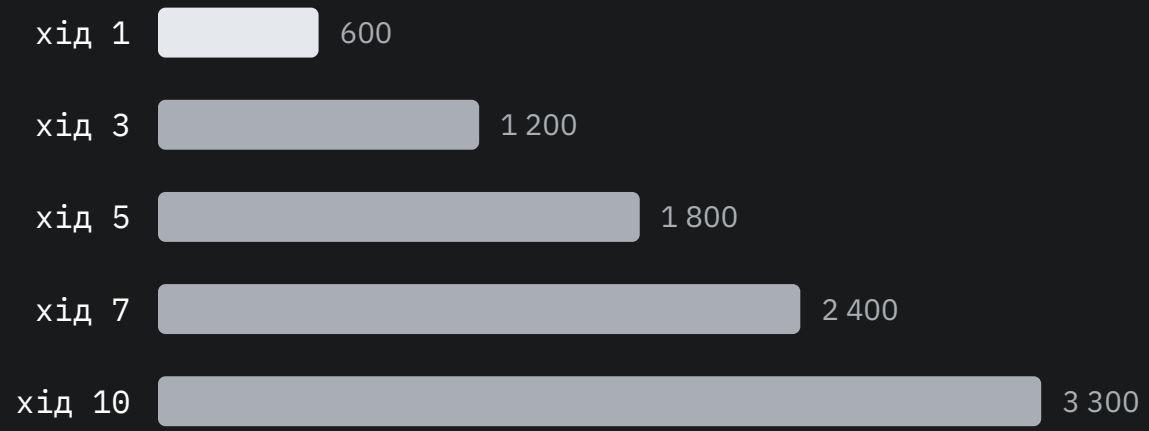
Версія моделі

Фіксуйте snapshot-назву: провайдери оновлюють і виводять моделі. Після зміни — прогін тестів.

Правило: модель пропонує — код приймає. Усе, що можна перевірити кодом, перевіряйте кодом.

TOKENOMICS: ДІАЛОГ ДОРОЖЧАЄ

Приклад: system prompt 500 · повідомлення 100 · відповідь 200 токенів



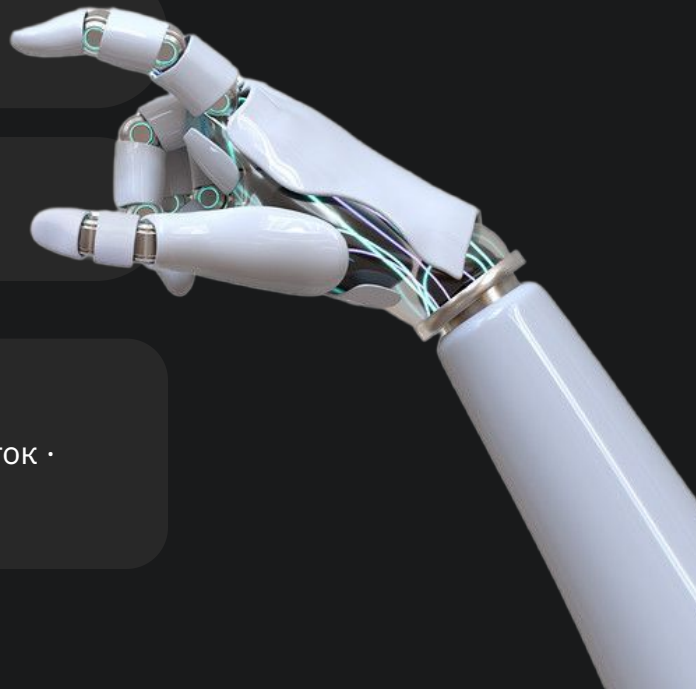
Вхідні токени одного запиту

1. Модель не пам’ятає розмову
2. Кожен запит несе всю історію
3. 10 ходів = 19 500 вхідних токенів
4. Нового тексту — лише 1 500

Питання в чат: як би ви зменшили цю суму, не втративши потрібний контекст?

СКІЛЬКИ КОШТУЄ ЗАПИТ

$0.15	за 1 млн вхідних токенів · gpt-4o-mini
$0.60	за 1 млн вихідних — у 4 рази дорожче
≈ $41	на день: 10 000 діалогів по 10 ходів



Що знижує рахунок

Обрізати історію · коротші відповіді · prompt caching: незмінне — на початок · Batch API: близько −50% для фонових задач.

LATENCY: З ЧОГО СКЛАДАЄТЬСЯ

01

Мережа і черга

Шлях до провайдера і очікування вільного сервера. Росте в пікові години.

Для інженера

Timeout з запасом, retry, регіон ближче до користувачів.

02

Prefill

Модель читає весь промпт за один прохід. Разом з 01 це TTFT — час до першого токена.

Для інженера

Коротший промпт і кешування зменшують TTFT.

03

Decode

Генерація токен за токеном. 300 токенів при 60 ток/с = 5 с — найбільша частина.

Для інженера

Головний важіль — коротша відповідь. Для чатів — streaming.

SELF-HOSTED: КОЛИ ВИПРАВДАНО

ВИПРАВДАНО

- Air-gapped або жорстка регуляція
- Великий рівний потік простих запитів
- Власна fine-tuned модель
- Мала модель справляється з задачею

ІЛЮЗІЯ ЕКОНОМІЇ

- GPU платний щогодини, навіть без запитів
- Налаштування, моніторинг, оновлення
- Час інженера на підтримку
- Більше помилок малої моделі

Рахунок: GPU ≈ $0.7–1/год → $500–720/міс. Ті самі $720 через API ≈ 4.8 млрд вхідних токенів gpt-4o-mini.

Приватність без свого заліза: Azure OpenAI, Bedrock, Vertex: дані не йдуть у навчання, регіон обираєте ви.

ВИБІР МОДЕЛІ: ЧОТИРИ ПИТАННЯ

Якість

20–50 прикл.

Чи справляється на ваших реальних прикладах? Бенчмарки — лише орієнтир.

Вартість

$ / міс

Ціна запиту × кількість запитів на місяць. Рахуйте до запуску, а не після рахунку.

Приватність

NDA, ПД

Які дані йдуть у запит і чи можна віддавати їх цьому провайдеру?

Обмеження

SLA

Latency, rate limits, розмір контексту, підтримка structured output.

ПРАКТИКА: ОДНА ЗАДАЧА — ТРИ РЕАЛІЗАЦІЇ

```
client = OpenAI(base_url=BASE_URL, api_key=API_KEY,
                timeout=30, max_retries=2)
r = client.chat.completions.create(
    model=MODEL, temperature=0, messages=[...],
    response_format={"type": "json_schema", ...})
ticket = Ticket.model_validate_json(
    r.choices[0].message.content)
```

1. **Провайдер · gpt-4o-mini**
   еталон якості
2. **Дешевша модель**
   скільки якості втрачаємо
3. **Локально · llama3.2:3b**
   Ollama, без оплати за токени



ТАБЛИЦЯ ТРЕЙД-ОФІВ · ЧАТ І SOLUTION

Модель	Час · медіана	Вартість 5 звернень	JSON · кат.
gpt-4o-mini · провайдер	… с · … с	$ …	…/5 · …/5
llama-3.1-8b · дешевша	… с · … с	$ …	…/5 · …/5
llama3.2:3b · локально	… с · … с	$0 + залізо	…/5 · …/5
Висновок для кейсу		Що обрали б для продакшну і чому?	

КЕЙС: ЯК МИ ОБИРАЛИ МОДЕЛЬ

Задача

[Що робила система, обсяг запитів, які дані йшли в модель — знеособлено]

Що порівнювали

[Модель A · провайдер]
[Модель B · дешевша]
[Модель C · локальна]

[критерії: якість · вартість · latency · приватність]

Що обрали і чому: [рішення і головний аргумент]

1 Що не спрацювало: [...]

2 Що виміряли: [...]

3 Що зробив би інакше: [...]

ЗВ’ЯЗОК З КЕЙСОМ 1 · КРОК 2

1 → **Задача**
ваш курсовий

2 → **Еталон**
провайдерська модель

3 → **Друга модель**
дешевша або локальна

4 → **Ті самі дані**
20–50 прикладів

5 → **Заміри**
якість · $ · latency

6 **Звіт**
таблиця + вибір

З чого почати

Візьміть скрипт з практики, підставте свою схему і свої тексти. Спершу 5 прикладів, потім усі.

Типові помилки

Різні дані для різних моделей · заміри з холодним стартом Ollama · невалідні відповіді не враховані у звіті.

ПІДСУМКИ І ЩО ДАЛІ

1. Один OpenAI-сумісний код — будь-яка модель. Timeout, retry і валідація — обов’язковий мінімум.
2. Вартість діалогу росте з кожним ходом, а latency — з довжиною відповіді. Рахуйте до запуску.
3. Self-hosted — про приватність і контроль. Економія лише при великому рівному навантаженні.

22.10 Заняття 4 · Prompt engineering

24.10 Чекпоінт кейсу: кроки 1–2

26.10 Q&A-сесія

27.10 Дедлайн кейсу 1

Не встигли спитати? Пишіть у тред Slack — відповідь письмово до кінця завтрашнього дня.

Запис і повне рішення практики — у Slack до завтра

Q&A

???

r_d

ЗАВЖДИ Є КУДИ ЗРОСТАТИ